

Estatística Descritiva para Análise e Ciência de Dados

Exercício 1) Tabela de Frequências

Cenário: Satisfação do aplicativo (Produto)

Você é a Analista de Dados de uma startup que acaba de lançar uma nova funcionalidade no aplicativo. Após uma semana, o time de Produto enviou uma pesquisa de satisfação onde os usuários avaliavam a nova funcionalidade com notas de 1 (Muito ruim) a 5 (Excelente).

Abaixo estão as notas dadas por uma amostra de 20 usuários:

5, 4, 5, 3, 4, 5, 2, 5, 4, 5, 1, 4, 5, 3, 4, 2, 4, 5, 4, 3

A) Construa uma tabela de distribuição de frequências contendo:

Frequência Absoluta

Frequência Relativa

Frequência Absoluta Acumulada

Frequência Relativa Acumulada

Tabela que eu construí no Google Sheets:

A	B	C	D	E
notas	Frequência absoluta	Frequência relativa	Frequência absoluta acumulada	Frequência relativa acumulada
1	1	5,00%	1	5,00%
2	2	10,00%	3	15,00%
3	3	15,00%	6	30,00%
4	7	35,00%	13	65,00%
5	7	35,00%	20	100,00%
Total geral	20	100,00%		

B) O gerente de Produto perguntou: “Qual a porcentagem de usuários que deram nota 3 ou menos?”. Utilizando a sua tabela de frequências, qual coluna responde a isso de forma direta e qual é a resposta?

Minha resposta:

30% da amostra deram notas iguais ou menores que 3.

A coluna que utilizei foi a da Frequência relativa acumulada, na qual ela realiza a soma das proporções das notas.

Exercício 2) Média vs. Mediana (Outliers)

Cenário: Análise de Receita (Marketing e Vendas)

O time de Marketing fez uma campanha de anúncios que atraiu 7 novos clientes na última semana. O valor (ticket) da primeira compra de cada um desses clientes (em R\$) foi registrado no banco de dados da seguinte forma:

120, 150, 135, 140, 125, 160, 4500

O cliente que comprou R\$ 4.500 era de uma grande empresa (cliente B2B) que entrou por acaso no funil de vendas destinado a pessoas físicas.

A) Calcule a média e a mediana dos valores gastos por esses 7 clientes.

Minha resposta:

$$\text{Média} = (120 + 150 + 135 + 140 + 125 + 160 + 4500) / 7$$

$$\text{Média} = 5.330 / 7$$

$$\text{Média} = \text{R\$ } 761,43$$

Mediana

$$\text{pos} = \text{int}((7 + 1) / 2)$$

$$\text{pos} = \text{int}(8 / 2)$$

$$\text{pos} = \text{int}(4)$$

$$\text{pos} = 4$$

120 → posição 1

125 → posição 2

135 → posição 3

140 → posição 4 → Mediana

150 → posição 5

160 → posição 6

4500 → posição 7

B) Como Cientista de Dados, se o diretor de Marketing perguntar “Qual é o valor que o cliente típico dessa campanha gasta?”, você responderia com a média ou com a mediana? Justifique estatisticamente sua escolha baseada nos dados.

Minha resposta:

Eu responderia com a mediana, pois há um valor que não apresenta proximidade com os demais valores, fazendo com que o resultado da média se aproxime do valor discrepante, já que a média consiste no ponto mais próximo de todos os outros pontos de dados. Sendo assim, não sendo um resultado representativo.

Já a mediana é extremamente útil para esses casos em que há pontos de dados distantes, na qual ela pega o número que está entre a metade do conjunto: 50% do conjunto vai ser menor que esse número e os outros 50% vai ser maior.

Exercício 3) Quartis

Cenário: Tempo de entrega (logística)

Um e-commerce está analisando a eficiência de sua principal transportadora. Você extraiu os tempos de entrega (em dias úteis) de uma amostra de 11 pedidos recentes, que já estão ordenados de forma crescente para facilitar:

2, 3, 4, 4, 5, 6, 7, 8, 10, 12, 15

A) Encontre o primeiro Quartil, o segundo Quartil e o Terceiro Quartil

Minha resposta:

Primeiro quartil = $\text{int}(\frac{1}{4}(n + 1))$

$\text{pos} = \text{int}(\frac{1}{4}(12))$

$\text{pos} = \text{int}(12/4)$

$\text{pos} = \text{int}(3)$

pos 3 → 4 dias

2, 3, 4 → 25 % dos pedidos foram entregues em até 4 dias.

5, 6, 7, 8, 10, 12, 15 → 75% dos pedidos foram entregues em 4 dias ou mais. (O mínimo que demora)

Segundo quartil = $\text{int}((n+1) / 2)$

$\text{pos} = \text{int}(12/2)$

$\text{pos} = \text{int}(6)$

pos = 6 → 6 dias

Terceiro quartil = $\text{int}(\frac{3}{4}(n + 1))$

$\text{pos} = \text{int}(\frac{3}{4}(12))$

$\text{pos} = \text{int}(36/4)$

$\text{pos} = \text{int}(9)$

pos = 9 → 10 dias

12, 15 → 25% dos pedidos foram entregue em 10 dias ou mais.

2, 3, 4, 4, 5, 6, 7, 8 → 75% dos pedidos foram entregues em até 10 dias. (O máximo que demora)

B) O time de Logística quer colocar um banner no site com uma promessa de prazo de entrega. Eles perguntam a você: “Podemos garantir que 75% das entregas são feitas em até quantos dias?” Como o Q3 te ajuda a responder essa pergunta?

O terceiro Quartil, que separa aproximadamente 75% do conjunto de valores menores dos 25% maiores, indica que a entrega pode ocorrer em até 10 dias úteis. Pois, o terceiro quartil é 10, e 25% depois consta 12 e 15 dias.

Exercício 4) Somatório e Propriedades

Cenário: Vendas diárias e meta (operações)

Uma loja vendeu as seguintes quantidades de seu produto principal ao longo de 5 dias úteis, representadas pela variável x_i (onde i vai de 1 a 5):

$$x = [10, 15, 12, 20, 18]$$

A) A média de vendas diárias nesses 5 dias é exatamente 15. Calcule o valor do desvio das vendas em relação à média.

Desvios = distância entre cada ponto e a média.

Minha resposta:

$$\text{desvio} = (10 - 15) + (15 - 15) + (12 - 15) + (20 - 15) + (18 - 15)$$

$$\text{desvio} = (-5) + 0 + (-3) + 5 + 3$$

$$\text{desvio} = -5 - 3 + 5 + 3$$

$$\text{desvio} = 0$$

B) O resultado obtido foi coincidência?

Não foi coincidência. A soma dos desvios em relação à média é sempre igual a zero.